Bài tập lớn môn Kho dữ liệu và Khai phá dữ liệu

1. Tiêu đề đề tài và mô tả dữ liệu

Tiêu đề: Hệ thống gợi ý sản phẩm cá nhân hóa .

Mô tả dữ liệu: Hệ thống xử lý dữ liệu tương tác người dùng (click, view, add-to-cart, purchase, rating), hồ sơ người dùng (đặc tính demografic, lịch sử mua sắm), và dữ liệu mô tả sản phẩm (text mô tả, hình ảnh, thuộc tính). Dữ liệu này có thể bao gồm cả phản hồi rõ (ratings) và phản hồi ẩn (implicit feedback) như lượt click/mua. Đề tài chọn vì nhu cầu cá nhân hóa trong thương mại điện tử rất lớn, giúp tăng trải nghiệm người dùng và các chỉ số kinh doanh như CTR hay doanh thu. Các thách thức gồm độ thưa của ma trận tương tác và khối lượng dữ liệu lớn, đòi hỏi các kỹ thuật lọc cộng tác (matrix factorization) kết hợp với thông tin nội dung để xử lý hiệu quả.

2. Tính năng nghiệp vụ và KPIs thực tế

Các tính năng nghiệp vụ và kịch bản sử dụng điển hình gồm:

- **Đề xuất sản phẩm theo trang chủ/cá nhân:** Gợi ý sản phẩm “Có thể bạn quan tâm” hoặc “Khách hàng đã mua X cũng mua Y” trên trang chính hoặc trang chi tiết sản phẩm.
- **Gợi ý trong email marketing:** Gửi email cá nhân hóa đề xuất sản phẩm dựa trên lịch sử mua sắm của người dùng.
- **Gợi ý trong giỏ hàng/wishlist:** Đề xuất thêm sản phẩm phù hợp dựa trên sản phẩm trong giỏ hoặc wishlist hiện tại.
- **Thứ hạng kết quả tìm kiếm:** Cá nhân hóa bảng xếp hạng khi người dùng tìm kiếm sản phẩm.
- **Khuyến nghị theo phiên (session):** Trong cùng một phiên mua sắm, hệ thống phân tích hành vi gần nhất để gợi ý ngay lập tức.

Các chỉ số KPI quan trọng để đánh giá hiệu quả gồm:

- **Click-through rate (CTR):** Tỷ lệ người dùng bấm vào đề xuất so với số lần hiển thị. Ví dụ, nghiên cứu thực nghiệm cho thấy CTR có thể tăng đáng kể nếu giảm độ trễ truy xuất đề xuất.

- **Conversion rate:** Tỷ lệ người dùng thực hiện mua hàng sau khi tương tác với đề xuất.
- **Precision@K, Recall@K:** Độ chính xác và độ bao phủ tại vị trí K của khuyến nghị gợi ý so với sở thích thực tế của người dùng. Precision@K đo tỷ lệ sản phẩm gợi ý liên quan trong top-K; Recall@K đo tỷ lệ gợi ý trong top-K chiếm bao nhiêu phần trăm sản phẩm liên quan thực tế.
- **NDCG@K (Normalized Discounted Cumulative Gain):** Đo lường chất lượng xếp hạng đề xuất có xét đến vị trí ưu tiên (ví dụ sản phẩm đúng sở thích ở vị trí cao hơn sẽ cho điểm cao hơn). NDCG là thước đo phổ biến đánh giá xếp hạng trong hệ thống đề xuất.
- **A/B testing:** Thiết kế kiểm thử trực tuyến so sánh hai nhóm người dùng (nhóm có xem đề xuất mới và nhóm đối chứng) để so sánh thay đổi CTR, conversion. Ví dụ, nếu nhóm thử tăng CTR từ 0.08% lên 0.15% so với đối chứng, hệ thống được coi là hiệu quả.

3. Công cụ và vai trò

Các công cụ và thành phần hạ tầng có thể sử dụng (cả mã nguồn mở và dịch vụ thương mại):

- **DBMS và Kho dữ liệu (Data Warehouse):** Hệ quản trị quan hệ (MySQL, PostgreSQL) có thể dùng lưu trữ thông tin danh mục nhỏ, nhưng với quy mô lớn thường dùng kho dữ liệu phân tán (Amazon Redshift, Google BigQuery, Snowflake) hoặc data lake (HDFS, S3). Ví dụ Snowflake/Redshift hỗ trợ OLAP cho các truy vấn phân tích trên ma trận user-item lớn.
- **Streaming:** Apache Kafka (hoặc AWS Kinesis) để thu thập sự kiện thời gian thực. Kafka chịu trách nhiệm tạo luồng và lưu trữ log. Kafka Streams hoặc ksqlDB có thể dùng để tính toán đơn giản ngay trên luồng (ví dụ tính thời gian phiên, đếm sự kiện).
- **Batch Processing:** Apache Spark hoặc Apache Flink cho ETL và tính toán hàng loạt. Spark thường dùng cho xử lý dữ liệu lớn định kỳ (precompute user/item embeddings, thống kê lịch sử).

- **Feature Store:** (ví dụ Feast, Hopsworks) để lưu trữ và phục vụ tính năng được tính trước. Giúp chuẩn hóa cách đọc tính năng cho quá trình huấn luyện và cho service.
- **ML Libraries:** PyTorch hoặc TensorFlow cho huấn luyện mô hình deep learning (embedding, NN), Scikit-learn cho các mô hình truyền thống (FM, logistic regression, SVD). Dựng mô hình collaborative filtering có thể dùng thư viện implicit hoặc Spark MLlib (ALS).
- **Model Training Infrastructure:** Dùng GPU/CPU cluster, có thể dùng Kubeflow/MLflow pipelines để tổ chức.
- **Model Serving:** TensorFlow Serving, NVIDIA Triton hoặc REST API (Flask/FastAPI) để phục vụ mô hình. Ví dụ, TF Serving cho phép load mô hình SavedModel và thực hiện dự đoán qua REST/gRPC. Triton hỗ trợ đa mô hình, đa framework.
- **Monitoring:** Prometheus + Grafana để giám sát hệ thống (load CPU, độ trễ, throughput) và đo metric ML (CTR, độ chính xác trên tập kiểm thử, v.v). Dashboard Grafana cho phép trực quan hóa CTR theo thời gian thực.
- **Experiment Tracking:** MLflow cho theo dõi thí nghiệm (experiment). MLflow Tracking cung cấp API và giao diện UI để lưu tham số, version code, metrics và artifact (model) của mỗi lần chạy huấn luyện. Nhờ đó dễ so sánh các chạy, tìm model tốt nhất và quản lý phiên bản. MLflow hỗ trợ lưu trữ metric, tham số dưới dạng database (SQLite, MySQL) hay MLflow Server.

Công cụ / Hệ thống	Vai trò	Ghi chú
Apache Kafka	**Nền tảng streaming sự kiện (thu thập dữ liệu real-time)**	**Bảo đảm thứ tự, có khả năng replay.**

Apache Spark	**Xử lý dữ liệu hàng loạt (batch ETL, training)**	**Hỗ trợ MLlib (ALS), Spark Streaming.**
Hadoop/HDFS	**Data lake lưu trữ dữ liệu thô**	**Dùng cho lưu trữ linh hoạt quy mô lớn.**
Redshift/Snowflake	**Kho dữ liệu OLAP**	**Dùng truy vấn phân tích hiệu suất cao.**
Redis/Cassandra	**Lưu cache đề xuất hoặc feature thời gian thực**	**Phản hồi rất nhanh cho query mô hình.**
Feast	**Feature store**	**Quản lý feature pipeline giữa training và serving.**
PyTorch/TensorFlow	**Thư viện huấn luyện mô hình**	**Cả hai hỗ trợ GPU, TensorFlow Serving.**
Scikit-learn	**Thư viện ML cổ điển (FM, SVM, tree, v.v.)**	**Đơn giản, nhẹ cho thử nghiệm nhanh.**
TensorFlow Serving / Triton	**Phục vụ mô hình qua API**	**Hỗ trợ mô hình deep, có khả năng autoscale.**
Prometheus/Grafana	**Giám sát dịch vụ & mô hình**	**Báo thức hệ thống, dashboard KPI.**
MLflow	**Theo dõi thí nghiệm**	**Ghi log tham số/metrics/model của mỗi run.**

4. Mô hình gợi ý và chiến lược

Hệ thống sẽ kết hợp nhiều loại mô hình để khuyến nghị:

- **Collaborative Filtering (lọc cộng tác):** Sử dụng dữ liệu tương tác người dùng–sản phẩm để học không gian ẩn (latent factors). Ví dụ, **matrix factorization** (SVD, ALS) tìm các vector đại diện cho user và item sao cho tích vô hướng dự đoán tương tác (rating). Phương pháp này hiệu quả trong đánh giá các sở thích ẩn của người dùng và khắc phục độ thưa thông qua hạ bậc dữ liệu. Có hai biến thể: *explicit CF* dùng dữ liệu đánh giá rõ (sao rating), *implicit CF* dùng dữ liệu hành vi (click/view/purchase) và thường sử dụng negative sampling để tạo nhãn "không mua". Một ví dụ nổi tiếng là mô hình ALS của Hu và cộng sự.
- **Content-Based (dựa trên nội dung):** Sử dụng đặc trưng của sản phẩm để đề xuất sản phẩm tương tự. Ví dụ, vector hóa nội dung văn bản mô tả sản phẩm qua TF-IDF hoặc embedding (Word2Vec, FastText, hoặc BERT) để so sánh tương đồng. BERT có thể được dùng để trích xuất embedding ngữ cảnh cho mô tả sản phẩm, hoặc trong mô hình thứ tự như BERT4Rec phục vụ khuyến nghị theo trình tự (deep bidirectional embedding). Nghiên cứu cho thấy các embedding sâu (như BERT) kết hợp thông tin nội dung giúp mô hình hiểu ý nghĩa sản phẩm tốt hơn.
- **Hybrid (lai):** Kết hợp cả CF và content-based. Ví dụ, có thể kết hợp gộp đầu ra từ mô hình CF và mô hình content, hoặc dùng phương pháp stacking/blending. Chiến lược điển hình là *retrieval* + *ranking* hai bước: (1) Dùng CF hoặc định nghĩa heuristic nhanh để thu hẹp tập sản phẩm ứng viên (candidate generation); (2) Dùng mô hình học máy (ví dụ neural network) để xếp hạng (ranking) các ứng viên theo mức độ phù hợp, kết hợp cả embedding user và content features. Ưu điểm là tận dụng được cả thông tin tương tác lẫn nội dung, tăng khả năng thích ứng cho các sản phẩm mới (cold-start) có đặc trưng nội dung rõ ràng.

5. Nguồn dữ liệu tham khảo

Các bộ dữ liệu công khai điển hình cho đề xuất cá nhân hóa:

- **MovieLens** (GroupLens): bộ dữ liệu tiêu biểu chứa người dùng, phim và rating. Có nhiều phiên bản (100K, 1M, 20M, 25M…). Ví dụ Movielens 1M chứa ~1 triệu rating. (Trích dẫn: Harper & Konstan, 2015).
- **Amazon Reviews**: Dữ liệu đánh giá sản phẩm Amazon (hàng triệu đánh giá) dùng cho gợi ý và phân tích cảm xúc sản phẩm. Có nhiều tập nhỏ theo ngành (sách, điện tử, v.v.).
- **Retailrocket** (Kaggle): Bộ dữ liệu clickstream từ trang thương mại điện tử retailrocket.net gồm sự kiện (view, add-to-cart, transaction) và thông tin sản phẩm.
- **Instacart Market Basket** (Kaggle): Dữ liệu mua sắm từ Instacart gồm các giỏ hàng (orders) của người dùng, dùng để gợi ý sản phẩm thường mua.
- **Criteo Display Advertising**: Dữ liệu lớn về tương tác quảng cáo (click/no click) dùng để dự đoán CTR, có thể dùng như implicit feedback.
- **Alibaba/Taobao**: Có một số nghiên cứu sử dụng dữ liệu Taobao (thương mại điện tử Trung Quốc) nhưng thường không công khai đại trà. Alibaba cung cấp các dữ liệu cho các bài toán khuyến nghị quảng cáo (ví dụ Taobao Ad Display dataset của Alibaba, tuy khó truy cập).

